

面向指数增强策略的 量化算法优化设计与实现

Optimized Design and Implementation of Quantitative Algorithms for Index Enhancement Strategies

答辩人：廖望 | 学号：2210556

指导教师：刘晓光 教授

专业：计算机科学与技术 | 学院：计算机学院

南开大学 · 2026 年 5 月

研究背景：A 股指数增强场景

沪深 300 与 Smart Beta

- 沪深 300：中国大盘蓝筹核心基准指数
- Smart Beta = 被动指数跟踪 + 主动量化偏离
 - 兼具被动投资的低成本
 - 与主动管理的超额收益潜力
- 目标："Beta 稳健、Alpha 突出"

A 股非有效市场三大特征

- 散户主导：个人投资者占比高，错误定价频繁
- 政策市：宏观调控与监管对市场影响显著
- 流动性敏感：北向资金、M2 等宏观变量驱动 regime 切换
- → 纯西方因子框架难以直接套用

沪深 300 成分股对宏观经济与信贷周期高度敏感，需要本土化的量化增强方案

课题三大问题与本文应对

课题书指出的痛点

1. **计算量大**：传统多因子优化耗时长
2. **因子单一**：仅依赖价格 / 财务结构化数据
3. **缺乏不确定性量化**：单点预测无法风险感知

引入三大方向

- **AI 辅助决策**：LLM 舆情 + 异构集成
- **计算加速**：Numba JIT + 并行
- **外部数据**：宏观 + 新闻文本

本文四项创新（C1—C4）

- **C1** Claude Opus 4.7 中文舆情情感因子
- **C2** LightGBM+XGBoost+GRU+Ridge 异构 Stacking
- **C3** Split/Mondrian Conformal Prediction
- **C4** Numba JIT + joblib 并行回测引擎

算法创新与工程加速**双轮驱动**，全 CPU 友好，参数 $\leq$ 百万级

四项创新点矩阵概览

C1 LLM 舆情情感因子

Claude Opus 4.7 / Haiku 4.5 双通道 API；SHA-256 缓存 + 预算守门把昂贵 LLM 转为可控成本日频 alpha

实测 0.31 USD / 610 条新闻 · 单条 5.2×10^{-4} USD

C3 Conformal Prediction

Split / Mondrian CP 输出 90% 置信区间；三种置信加权 QP (alpha_scale / candidate_filter / objective_penalty)

α 敏感性偏差恒定 -9 pp；揭示 A 股"高置信即过拟合"反向规律

C2 异构 Stacking 集成

LightGBM + XGBoost + 轻量 GRU + Ridge 四 L1 模型 + MLP 元学习器；OOE KFold 训练规避标签泄漏

带约束 IR 5.92 > 5.84 (小幅但稳定击败单 LGBM)

C4 Numba JIT + joblib 加速

回测核心循环 @numba.njit 编译；joblib 并行驱动消融实验；NumPy fallback 保证降级可用

Kernel 级 130-310x / Engine 级 9.84x / 数值偏差 < $1e-15$

C1 基于大语言模型的舆情情感因子

管线四道防线


- **缓存**：SHA-256(text+model+prompt) 落 parquet，二次实验直接命中
- **双通道**：默认 Haiku 4.5 控本，关键样本切 Opus 4.7
- **批量 prompt**：每批 10 条新闻最大化 token 利用
- **预算守门**：BudgetTracker 累计 USD，超限即抛 BudgetExceededError

日频聚合（防泄露）

$$\text{sentiment}_{i,t} = \frac{\sum_k \text{polarity}_{i,t,k} \cdot \text{intensity}_{i,t,k} \cdot e^{-\Delta h/24}}{\text{count}_{i,t}}$$

- 16:00 后新闻自动计入下一交易日

C1 — LLM 中文财经舆情情感因子




C2 异构轻量多模型 Stacking 集成

L1 模型族 (全 CPU、参数 $\leq$ 百万)

- LightGBM: `n_est=300, lr=0.05, leaves=31`
- XGBoost: `tree_method=hist, max_depth=6`
- 轻量 GRU: 单层 $h=32$, PyTorch CPU, 参数约 5K
- Ridge: `RidgeCV` 含 `StandardScaler`

元学习器 (Wolpert 1992)

- 3 折 KFold 生成 OOF 元特征矩阵 $Z \in \mathbb{R}^{n \times 4}$
- 线性 / MLP / 平均三选一
- 自动对相关性的 L1 施加负向校正
 - 短样本中 Ridge 系数均值 ≈ -0.25




C3 Conformal Prediction 与置信加权组合

区间构造 (Vovk 2005)

- 训练子集按 70/30 分 `train_proper` 与 `calibration`
- 残差分位数 $q_\alpha = \text{Quantile}_{(n+1)(1-\alpha)/n}(|r|)$
- 区间 $[\hat{y} - q_\alpha, \hat{y} + q_\alpha]$, 置信度 $c_i = 1/(2q_\alpha + \epsilon)$
- **Mondrian** 版本按申万一级行业分组校准

三种置信加权 QP 方案

- `alpha_scale`: $\alpha'_i = \alpha_i \cdot c_i^\beta$
- `candidate_filter`: 仅置信 top 70% 进 QP
- `objective_penalty`: 加 $-\gamma \sum_i (1 - c_i) w_i^2$



C4 Numba JIT + joblib 并行回测引擎

Kernel 级加速


- `BaselineBacktestEngine._build_nav` 抽出 `compute_nav_loop`
- `@numba.njit(cache=True)` 装饰, LLVM JIT 类型特化
- 输入 $(n_d \times n_s)$ 收益矩阵 + 权重 + 基准 + 调仓掩码
- NumPy fallback 降级可用 (numba 未装时)

Engine 级加速 + joblib 并行

- `src.backtest.parallel`: `run_in_parallel` / `cached_to_disk`
- 模型中间产物 `joblib.dump` 缓存, 避免重复训练

9.84x Engine 加速

$<10^{-15}$ NAV 偏差



与 2025–2026 SOTA 工作的横向对照

LLM Agent

StockBench (污染洁净评测)
QuantAgent (多智能体 HFT, 最高 80% 方向准确率)
FinMem / AlphaAgent (分层记忆 / alpha 挖掘)
本文 C1 退而求次: LLM 仅作离线语义抽取, 把可控成本作为首要约束

MoE

MIGA (CSI300 24% 年化超额 SOTA)
LLMoE (LLM 作 MoE Router)
FTS–Text–MoE / AlphaMix
本文 C2 MLP 元学习器是其轻量级前置; 端到端 CPU 训练、解释性更好

Diffusion

Diffusion Factor Model (因子嵌入 score 函数)
Diffolio (条件扩散组合预测分布)
未来工作方向, 替代 Ledoit–Wolf 缩减; 本文优先工程可复现性

Adaptive CP

Gibbs ACI (在线调整 miscoverage)
SPCI / TCP / ECI / CPTC / ResCP
本文 C3 揭示 Split CP 系统性偏差; §6 简化模拟证明 ACI 可矫正 ~80% 偏差


定位: 覆盖广度与工程可复现性优先; §2.9 引 16 篇 2025–2026 顶会顶刊

长周期对比（2015–2024 沪深 300，10 年）

评价指标	多因子基线	LightGBM 基础	
年化超额	4.21%	28.07%	41.31%
夏普比率	0.168	1.289	1.881
信息比率	0.237	1.685	2.449
最大回撤	−58.53%	−31.71%	−25.37%
年化换手	0.125	2.083	2.242

关键发现

- IR 由 0.24 → 1.69 → 2.45（约 10× 提升）
- 最大回撤由 −58.5% → −25.4%（回撤减半）
- 外部宏观 + 行业中性化 + Ledoit–Wolf 三者叠加生效




五策略最终对比（2024–2025 真实回测）

策略	IR	年化超额	最大回撤	换手
基线（等权 Top20）	0.732	7.43%	−12.85%	5.13
LGBM（无优化器）	13.733	396.80%	−10.03%	9.93
LGBM + 优化器	5.839	66.31%	−9.22%	2.30
Stacking + 优化器	5.919	68.13%	−10.26%	2.29
Conformal + 优化器	5.634	65.41%	−9.50%	2.30

关键结论

- 等权 IR 13.73 仅是上限参考（换手 9.93 超实施边界）
- Stacking IR 5.92 > LGBM IR 5.84：异构集成稳定小幅胜出
- Conformal IR 5.63 略低：低 SNR 下置信信号需更长样本




C1 LLM 舆情打分质量验证

实测数据

- 样本：61 只成分股 × 610 条新闻 × 2 个月
- 模型：claude-haiku-4-5 (10 USD 预算上限内运行)
- 成本：0.31 USD (单条 5.2×10^{-4} USD)
- polarity 均值 0.119、std 0.516 (不退化为常数)
- 范围 $[-0.95, 0.95]$ ，主题分布合理

诚实披露的局限

- 端到端 IR 增益当前为负 (-2.85%)
- 原因：时间移位后非零 sentiment 覆盖率仅 **0.32%**
- 在 9/11 个滚动窗口中三列全 0、无法分裂
- → 后续需扩到 2024–2025 完整新闻语料，覆盖率提至 50%+



C3 "高置信即过拟合" 反向规律的三层证据


反向规律观察

置信桶	样本数	IR	命中率
高 (top 30%)	804	-0.140	0.425
中 (mid 40%)	1072	-0.028	0.419
低 (bottom 30%)	804	+0.454	0.484

三层独立稳健性证据

- 1. α 敏感性：偏差 $-8.4 \sim -9.2$ pp (与 α 无关)
- 2. Mondrian 真实数据：覆盖率仅微涨 0.4 pp；高置信桶 IR 恶化至 -0.21
- 3. ACI 模拟： $\gamma=0.005$ 时估算覆盖率达 89.7%，矫正 $\sim 80\%$ 偏差

排除数据偶然，揭示 A 股低 SNR 下 CP 的方法学局限




C4 Kernel 级 vs Engine 级加速比 Surface

Kernel 级（裸 NumPy，零 pandas 依赖）

n_stocks	n_days	Python (ms)	Numba (ms)	加速比
50	252	1.75	0.01	130×
100	252	3.25	0.01	310×
300	252	10.00	0.03	300×
300	1260	48.94	0.21	235×
300	2520	96.68	0.36	266×

核心结论

- Kernel 级 130–310× 稳定保持（LLVM 类型特化）
- Engine 级 9.84× 受 pandas/dict 开销限制
- 偏差恒等 0（同序浮点运算）
- 工程优化方向：record array 替换 DataFrame，逼近 100× 量级



综合稳健性：11 维度敏感性测试

测试维度	设定	关键发现
约束消融（4 项）	跟踪误差 / 行业 / 换手 / 全部	完整约束是收益-可实施性最优折中
特征分组消融	factor-only vs +external	外部宏观因子贡献 +50% IR
训练窗口（长样本 12/24/36/60）	月度滚动重训	12 月最优 IR 1.53, 强非平稳性
5-seed 稳定性	seeds {7, 42, 123, 2024, 314159}	IR CV 仅 1.85% （非 cherry-pick）
严格 OOS	长历史训练 → 2025 测试	近期窗口 IR 2.86 / 长历史 IR -0.48
Conformal α 敏感性	$\alpha \in \{0.05, 0.10, 0.20\}$	偏差恒定 -8.4 ~ -9.2 pp
Mondrian 复测	合成 vs 真实	真实数据未矫正反向规律
ACI 模拟	$\gamma \in \{0.005, 0.01, 0.05, 0.1\}$	$\gamma=0.005$ 时矫正 ~80% 偏差
持仓数 Top-N	10/20/30/50	Top 20 IR-回撤折中点, TC $\approx$ 0.82
Numba 规模 surface	50-500 股 $\times$ 252-2520 日	加速比稳定 130-310x
五策略对比	4 模型 $\times$ 优化器	Stacking IR 5.92 > LGBM IR 5.84

三类核心稳健性证据：①Stacking 持续小幅胜出 ②CP 反向规律三层独立验证 ③Numba 跨 5 量级稳定加速

核心结论与未来工作

四项主要结论

- **C1**: SHA-256 缓存 + 预算守门 + 双通道 → LLM 工程化范式, 单次实验 ≤ 10 USD
- **C2**: MLP 元学习器自动给 Ridge 赋负权重, 短样本上 Stacking IR **5.92** vs LGBM **5.84**
- **C3**: 揭示 A 股"高置信即过拟合"反向规律; 偏差恒定 -9 pp (α 无关)
- **C4**: Kernel 级 $130-310\times$ / Engine 级 $9.84\times$ / 数值偏差 $< 10^{-15}$

未来工作路线图

- **C1 升级**: 扩展至完整新闻 + 公告语料, 对接 StockBench 污染洁净评测
- **C2 升级**: MoE 路由 (MIGA / LLMoE) 替换 MLP 元学习器
- **C3 升级**: Adaptive CP (TCP / ECI / CPTC / ResCP) 矫正系统性偏差
- **C4 升级**: 跨节点 Dask/Ray, LightGBM GPU 后端
- **整合**: LLM Agent 决策融合 (QuantAgent / Karim Agentic Regime)

长周期约束型 LightGBM: IR 由静态多因子的 **0.237** → **2.449**, 最大回撤 **-58.53%** → **-25.37%**

致 谢

感谢指导教师 **刘晓光教授** 一年来的悉心指导

感谢南开大学计算机学院的培养

感谢家人朋友的支持与陪伴

恳请各位老师批评指正

Q&A 速查（一）：创新点质量

Q1 你的创新点是不是"工程整合"而非"算法贡献"？

C1 是工程范式（SHA-256 + 预算守门 + 双通道）；C2 Stacking IR 5.92 > 5.84 是算法贡献；C3 反向规律是实证发现性算法贡献（三层证据稳健）；C4 Numba 是工程加速直接呼应课题书核心痛点。

Q2 与 2026 SOTA（如 MIGA CSI300 24%）相比有何价值？

MIGA 是 MoE 大参数，本文是轻量 Stacking、CPU 友好、参数 ≤ 百万。两者在覆盖广度与工程可复现性之间形成清晰折衷 —— MIGA 追求 SOTA 收益，本文追求资源受限场景的"开源可复用基线"。

Q3 你的 sentiment 因子端到端 IR 增益为什么是负的？

§3.19 已诚实披露：sentiment 时间窗口仅 2 个月、覆盖 61 股，移位后只有 0.32% 面板行有非零 sentiment，9/11 滚动窗口三列全 0、无法分裂。IR -2.85% 是常量特征引入的子采样扰动，非 sentiment 真正损害性能。

Q&A 速查 (二): 实证可信度

| Q4 等权 Top20 IR 13.73 是不是 cherry-picked?

不是。§5.12 用 5 个随机种子 {7, 42, 123, 2024, 314159} 重跑, IR 变异系数仅 1.85% (均值 7.01 / std 0.13)。13.73 是 `train_months=3` 极短窗口结果, 本文最终选 6 平衡, 对应 IR 7.13。

| Q5 短样本 (2024–2025) 17 个月的 IR 数字可信吗?

应作为"无约束上限"参考, 不构成可投资基线。§5.9 明确区分: 等权 IR 13.73 是上限, 启用优化器后 IR 5.84 才是符合"指数增强"定义的现实数字。论文同时给出长周期 2015–2024 实证 IR 0.24 → 2.45 验证一致性。

| Q6 Conformal 反向规律会不会是数据偶然?

§5.7 用三层独立测试佐证: ① **α 敏感性**: 偏差恒定 $-8.4 \sim -9.2$ pp (与 α 无关); ② **Mondrian 真实数据**: 覆盖率仅微涨 0.4 pp, 高置信桶 IR 进一步恶化到 -0.21 ; ③ **ACI 模拟**: $\gamma=0.005$ 估算覆盖率 89.7%。三层证据排除数据偶然性。

Q&A 速查（三）：技术细节

| Q7 为什么用 LightGBM 而不用 XGBoost / RF / DL?

A 股低信噪比 + 中小样本 + CPU 限制 → LightGBM 在特征捆绑（EFB）与单边采样（GOSS）上的工程优势能抵御噪音、提升泛化。§5.6 表格也对比了 LGBM / XGB / Ridge 三模型 IR 接近，**LGBM 优势非独有**。

| Q8 为什么选 train_months=12（长周期） / 6（短周期）？

§5.10 表格：长周期 12 月 IR 1.53 > 24 月 1.19 > 60 月 0.61，**强非平稳性主导**；短周期 6 月兼顾测试集留出 11 个月与训练集 6 个月样本量。

| Q9 为什么 top_n=20?

§5.9 表格：Top 10 IR 8.26 / 20 IR 7.13 / 30 IR 6.37 / 50 IR 4.98。Top 20 是 IR 与回撤 / 换手的折衷点 —— 再缩到 Top 10 推高换手到 10.47，**超出指数增强产品实施边界**。

| Q10 Numba 加速比 9.84x 是不是夸大？

§5.8 分两层说明：**Engine 级 9.84x** 含 pandas/dict 不可加速开销；**Kernel 级 130—310x** 是裸 NumPy 数组 NAV 累乘核（§5.8.1 表）。两数字共存，明指未来优化空间。

Q&A 速查（四）：风险与局限

Q11 你的策略在实盘能跑吗？

等权 Top20 IR 13.73 **不构成可投资基线**（换手 9.93 超实施边界）。LightGBM + 优化器 IR 5.84、换手 2.30 才是落地现实数字。本文给出的是"研究框架"而非"实盘策略"，实盘还需流动性、对手盘、监管约束等考量。

Q12 严格 OOS（2015–2024 训练 → 2025 测试）为什么 IR 是负？

§5.10 证实 A 股**强非平稳性**：长历史训练反而引入过时风格噪声。这是诚实披露的负面发现，也直接支撑 §4.1 "高频滚动重训"机制的设计。论文未隐藏该结果。

Q13 LLM 调用是否存在未来信息泄露？

§4.2 设计：publish_time **16:00 前的新闻计入当天，之后计入下一交易日**，避免泄露。所有 LLM 调用通过 SHA-256 缓存可复现，prompt 中明确"不要使用未来日期信息"。

Q14 Conformal Prediction 的可交换性假设在金融时序成立吗？

不严格成立。§2.7 已指出截面相关性与时间漂移会破坏 exchangeability，这正是本文 -9 pp 系统性偏差的根源；§6.3 的 ACI / TCP / ECI / CPTC / ResCP 升级方向就是为矫正这一假设破坏。

关键数字速查表

维度	数字	论文位置
C1 成本	0.31 USD / 610 条新闻; 5.2×10^{-4} USD/条	§5.5
C1 polarity	均值 0.119 / std 0.516 / 范围 [-0.95, 0.95]	§5.5
C2 IR (带约束)	Stacking 5.919 > LGBM 5.839	§5.9
C3 覆盖率偏差	恒定 -8.4 ~ -9.2 pp (α 无关)	§5.7.4
C3 反向规律	高置信桶 IR -0.14; 低置信桶 IR +0.45	§5.7.2
C4 Kernel 加速	130-310 $\times$ (50-300 股 $\times$ 252-2520 日)	§5.8.1
C4 Engine 加速	9.84 $\times$ (10 年 $\times$ 16 因子 $\times$ 300 股)	§5.8
C4 数值偏差	$< 10^{-15}$ (Kernel) / 严格 0 (规模 surface)	§5.8
长周期 IR	静态多因子 0.237 $\rightarrow$ +宏观 LW 2.449	§5.4
长周期最大回撤	-58.53% $\rightarrow$ -25.37%	§5.4
5-seed 稳定性	IR 变异系数 1.85% (均值 7.01 / std 0.13)	§5.12
严格 OOS	近期窗口 IR 2.86 / 长历史 IR -0.48	§5.10
论文体量	6 章 / 18 张图 / 51 篇文献 (含 16 篇 2025-2026)	—

完整代码与数据: <https://github.com/aokimi0/IndexEnhancementStrategy>